


sgRNA文库检测

分析报告



电话: 400-688-9033

网址: www.ubigene.com

地址: 广州市黄埔区开源大道198号中巨华夏科技园

美国办事处: 855 777 3210

欧洲办事处: 800 3272 9252

亚太联系方式: 001 800 3272 9252

01 项目摘要(摘要)


gRNA文库构建基本原理是通过一段与靶标DNA相同的gRNA指导Cas9核酸酶对靶向基因进行DNA修饰，以此造成基因的功能突变或缺失。在此基础上，利用CRISPR/Cas9技术建立哺乳动物全基因组突变库或者与某类功能相关的基因突变体库，通过功能性筛选和富集以及随后的PCR扩增和深度测序分析，发掘与筛选表型相关的基因，称为 CRISPR/Cas9 gRNA文库筛选。

gRNA文库是药物筛选或靶向筛选特定通路的理想工具，gRNA文库的建立将在功能基因筛选、疾病机制研究及药物研发等方面发挥重要的功能。gRNA文库包括全基因组文库、lncRNA文库、信号通路、细胞凋亡、细胞增殖、离子通道、核受体相关、各种疾病相关等文库。全基因组gRNA文库的构建可以针对任何类型的基因组DNA，包括ORF cDNA，lncRNA cDNA以及特定区域的cDNA片段等。能够针对全长cDNA乃至基因组DNA构建高效的RNA文库，适用于高通量功能基因及相关药物靶点筛选。

02 实验流程

2.1 文库制备

DNA样品经DNA片段化(Shear)、末端补平(End repair)、片段3'端加A尾(Add 3'A Tail)、连接接头(Ligate Adapt-ers)、片段筛选(Clean)、PCR扩增(Enrich with PCR)、片段筛选(Clean)、PCR产物质检(QC)等步骤构建形成Illumina平台高通量测序文库。



文库制备流程图



2.2 测序：illumina平台上机测序

2.3 数据分析

2.3.1 测序数据质控

对原始测序数据进行质量控制，去除raw datas中低质量的、较短的reads，得到clean datas。

2.3.2 reads比对

从reads中提取gRNA序列，比对到sgRNA文库的参考序列

2.3.3 统计分析

对比对结果进行统计分析，包括完全匹配的reads数量，匹配到的sgRNA、基因数量和覆盖率、均一性等指标

03 数据分析

3.1 测序数据简要信息

样品名	Clean reads数	sgRNA数	覆盖数	未覆盖数	覆盖率	均一性
GK250830-01	37917428	70296	69343	953	98.6%	8.91

3.2 测序数据评估

fastq是测序数据下机格式，其中包含测序序列(reads)的序列信息，及其对应的测序质量信息。fastq格式文件中每个read由四行描述，如下：

```
@A00133:594:HHNCVDSX3:4:1101:15374:1000 1:N:0:GGAGCTAC+AGGCTTAG
AATGGACTATCATATGCTTACCGTAACCTGAAAGTATTCGATTCTTGGCTTTATATATCTTGTGGAAGGA
+
FFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFF,F,:FFFFFF,FFFFFFFFFFFF
@A00133:594:HHNCVDSX3:4:1101:16007:1000 1:N:0:GGAGCTAC+AGGCTTAG
AATGGACTATCATATGCTTACCGTAACCTGAAAGTATTCGATTCTTGGCTTTATATATCTTGTGGAAGGA
+
FFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFF
```

第一行以“@”开头，后面是这个read的基本信息，分为两部分：ID部分和可选的描述部分，中间用空格分开，ID部分是每条read的唯一标识，它包含多个字段，每个字段之间用冒号分隔；描述区域是可选的，用来保存一些自定义的信息，如测序时用到的引物序列信息等。

第二行是碱基序列(分ATCGN5种情况，N代表不确定碱基类型)。

第三行用于将测序序列和质量值内容分离开来，以‘+’开头，后面可添加第一行的描述信息。

第四行为对应碱基序列的测序质量(以ASCII码形式储存，与第二行的碱基序列一一对应)




3.2.1 测序数据质控

测序得到的原始测序序列，里面含有带接头的、低质量的reads。为了保证信息分析质量，需要对raw reads进行精细过滤，得到clean reads，后续分析都基于clean reads进行。

数据处理的步骤如下：

- 去除长度小于50的reads对；
- reads中N碱基的比例大于10%时，需要去除此对reads；
- 去除Q20小于80%的reads对(Q20指reads的碱基质量分数大于等于20)

Raw reads classification



3.2.2 测序质量与错误率分布统计

测序错误率与碱基质量有关，受测序仪本身、测序试剂、样品等多个因素共同影响。对于Illumina高通量测序平台，测序质量和错误率分布具有两个特点：

- 每个read的前几个碱基的测序质量一般较低，这是由于边合成边测序过程初始阶段，测序仪荧光感光元件对焦速度较慢。获取的荧光图像质量较低，导致碱基识别错误率较高。
- 随着测序的进行，错误率会升高，测序质量降低，这是由于测试过程中荧光基因的不完全切割和de-phasing引起荧光信号衰减。



如果碱基的质量分数用Q表示，识别错误率用P表示，则碱基的质量分数和错误率能用以下公式表示：

$$Q = -10 \times \log_{10} P$$

$$P = 10^{-Q/10}$$

表1：碱基质量分数与识别错误率的关系表

Phred Quality Score	Probability of error	Base call accuracy
10	1/10	90%
20	1/100	99%
30	1/1000	99.9%
40	1/10000	99.99%
50	1/100000	99.999%

reads的碱基平均质量分数和平均错误率统计

各样本在read的不同测序位置碱基平均质量值和平均测序错误率统计如下图所示。



注：碱基质量值与错误率：
横坐标为read中的碱基位置，纵坐标为对应碱基位置的平均质量值

3.2.2 测序数据统计

Table 测序数据统计

Sample	GK250830-01
Raw reads	38051959
Clean reads	37917428
Effective rate(%)	99.65
Q20(%)	99.72
Q30(%)	98.25
GC ration(%)	34.64

Sample: 样本名称

Raw reads: 原始reads数

Clean reads: 经过滤后的有效reads数

Effective rate(%): 过滤得到的clean data reads数占raw data reads数的比例

Q20(%): 测序质量值大于20的碱基占总碱基的比例

Q30(%): 测序质量值大于30的碱基占总碱基的比例

GC ratio(%): GC碱基的总含量

3.3 Reads比对数据统计

3.3.1 比对数据统计

从reads中提取sgRNA序列，比对到sgRNA文库的参考序列，并对比对结果进行统计，包括完全匹配的reads数量，匹配到的sgRNA、基因数量和覆盖率、均一性等指标。根据这些指标可反映数据的可靠性和准确性

Sample	GK250830-01
Mappedreads	27551149(72.7%)



Grna_mean_depth	392
Max_Depth	31737
Median_depth	314
Totalgrnas	70296
Zerogrnas	953
Coverage_rate	98.6%
Totalgenes	70296
Zerogenes	953

注：比对信息统计表

Read: gRNA reads总数

MappedReads: 完全比对上gRNA Library的reads数目

Grna_mean_depth: gRNA平均测序的深度，即比对上参考序列的gRNA reads的总数目除以gRNA Library中被比对的gRNA数据

Max_Depth: gRNA最高测序深度，即gRNA Library中所有gRNA中比对上最多reads的gRNA的比对数目

Median_depth: gRNA测试深度的中位数

Totalgrnas: gRNA Library中的gRNA数目

Zerogrnas: gRNA文库中丢失的gRNA数目

Coverage_rate: 文库覆盖度，即测到的gRNA占总gRNA的比率，对于文库质控，一般要求覆盖度>90%


Totalgenes: gRNA library对应基因总数

Zerogenes: 未能检测到的基因数目

3.3.2 测序深度

根据sgRNA文库中每条sgRNA比对到的reads数目，进行归纳统计，并将统计结果可视化，直观的展示sgRNA的测序深度分布情况。如图所示：






注：横坐标为测序深度的Log2值，纵坐标为对应的gRNA数目

3.3.3 均一性

文库均一性用skew ratio表示，是累积分布达到90%时对应的gRNA数目与累积分布达到10%时对应的gRNA数目的比值，skew ratio小于10则认为文库的均一性合格。文库的均一性评估在功能筛选上是非常重要的，可以有效避免sgRNA的缺失导致的筛选阳性靶点的遗漏以及假阳性结果。



注：横坐标为测序深度，纵坐标为gRNA累计频率，左下值为10%pct对应的gRNA数目，左中值为90%pct对应的gRNA数目，Skew Ratio为二者比值(即90%分位数和10%分位数的比值)。

